

Wprowadzenie:

Projekt zakłada stworzenie systemu, który ułatwia analizę danych i podejmowanie decyzji dzięki algorytmom data science. Nasz skrypt R bada informacje zawarte w tekstach, korzystając z metod poznanych na zajęciach z Projektowania Systemów Informatycznych na WNE UW. W praktyce sprawdzamy jakich słów używają najczęściej politycy przeciwstawnych opcji politycznych w różnych kontekstach politycznych i jak nacechowane są ich wypowiedzi.

Cele systemu:

- Stworzenie działającego skryptu w języku R.
- Analiza danych tekstowych z jednego lub wielu plików .txt przy pomocy metod poznanych podczas zajęć PSI na WNE UW.
- Zidentyfikowanie oraz zbadanie trendów w danych tekstowych i interpretacja otrzymanych wyników.
- Wygenerowanie raportu HTML ze skryptu R z opracowaną kompletną dokumentacją systemu zgodną z podejściem inżynierii oprogramowania.
- Spełnienie standardów Reproducible Research, polegające na zapewnieniu, że kod oraz dane są dostępne w formacie możliwym do powtórzenia i odtworzenia

Wymagania funkcjonalne:

- Użytkownik powinien mieć możliwość uruchomienia analizy na dostarczonych danych (plikach .txt).
- System musi analizować dane przy użyciu przynajmniej dwóch z wymaganych technik: analizy częstości słów oraz analizy sentymentu.
- System musi dokonywać lematyzacji i przetwarzania tekstu
- Skrypt musi identyfikować i usuwać polskie stop words, a także słowa związane z adnotacjami stenogramów np. "oklaski", "wesołość" i czasowniki metatekstowe.
- System wczytuje i wykorzystuje w analizie predefiniowany słownik polityczny, klasyfikujący słowa jako pozytywne lub negatywne.
- W projekcie powinny znaleźć się elementy wizualizacji wyników, takie jak chmury słów oraz wykresy.

Wymaganie нефunkcjonalne:

- Kod źródłowy w R musi być czytelnie napisany i oparty na jasnym podziale na sekcje wraz z komentarzami.
- Cały projekt musi zostać umieszczony i udostępniony w repozytorium GitHub.
- Repozytorium ma stanowić format umożliwiający pełną odtwarzalność przeprowadzonych badań przez osoby trzecie.

Interfejsy użytkownika i wymagania dotyczące danych:

- Głównym interfejsem dla użytkownika jest środowisko języka R.
- Danymi wejściowymi są pliki tekstowe o rozszerzeniu .txt zakodowane w formacie UTF-8.
- Każdy plik wejściowy musi reprezentować jedną wypowiedź pojedynczego polityka.
- Użytkownik wykorzystuje zestaw ścieżek przyporządkowanych do określonych folderów podziału, co pozwala systemowi kategoryzować wypowiedzi dla poszczególnych grup.

Słownictwo dokumentacji:

Analiza sentymentu: Metoda badania nacechowania emocjonalnego tekstu (słów) polegająca na jego zestawieniu z pojęciami zdefiniowanymi jako negatywne i pozytywne.

Lematyzacja: Proces normalizacji językowej mający na celu sprowadzenie każdego ze słów tekstu źródłowego do formy podstawowej (lematu) przed obliczeniem ich wystąpień.

Stop words: Powszechne w języku zaimki, przyimki, a w kontekście tego projektu także słowa stenograficzne, które ze względu na brak wpływu na sens merytoryczny są usuwane.

Reproducible Research: Podejście gwarantujące przejrzystość procesów analitycznych oraz upublicznienie kodu, w taki sposób, aby badanie można było wiarygodnie odtworzyć

Use cases:

Inicjalizacja badań i konfiguracja skryptu: Użytkownik instaluje potrzebne pakiety, konfiguruje katalog roboczy oraz wczytuje udostępniony model językowy i słownik sentymentu.

Wprowadzenie zbioru danych: Użytkownik uzupełnia we wskazanych fragmentach kodu listy plików tekstowych poszczególnych polityków w podziale na 4 kategorie badawcze (PiS/PO oraz władza/opozycja).

Uruchomienie automatycznej lematyzacji i filtracji: Skrypt na żądanie użytkownika czyści tekst ze znaków i przypisuje słowa do podstawowych form przy użyciu pakietu udpipe.

Generowanie obiektów graficznych: System wykreśla chmury słów poleceniem wordcloud dla poszczególnych badanych grup na bazie ich wyliczonej częstotliwości występowania.

Scenariusze użytkownika:

Jako autor badania chcę zbadać zmianę sentymentu w wypowiedziach polityków w zależności od wyników wyborów.

Jako świadomy wyborca, chcę zbadać stabilność sentymentu i najczęściej używanych słów przez wybranych polityków.